AI Detector

从合成输入到可审查的评分与调查边界

3–5 分钟技术演示 · CW-020

研究原型，不是生产交易风控系统

系统先回答三个问题

评分服务读什么?

冻结的 LightGBM bundle 和版本化政策。

什么可以外发?

只有决策快照与已审查上下文。

失败时发生什么?

输入拒绝
服务不就绪
候选降级或拒绝。

核心取舍：让“可复现的评分”与“可选的调查生成”分开。

离线训练：先冻结证据，再交付模型

关键顺序

匿名 CSV
时间切分
train-only 预处理
LightGBM + validation 早停
validation 分数与 F1 阈值
test 一次评估
bundle

图示口径：CW-019 已验收架构图
本页用大字号流程保留同一事实链，避免缩小图中文字。

训练规则
validation 用于早停和阈值冻结
test 只做一次评估
服务端不读取原始 CSV

服务只读加载 bundle，不读取原始 CSV。

请求时评分：调查生成是可选路径

评分主路径

199 列契约
bundle SHA-256 校验
LightGBM 分数
政策与风险响应

显式调查路径

DecisionSnapshot + 审查上下文
DeepSeek（可选）
不可信候选
CW-016 独立校验

默认服务、默认测试和 CI 不调用外部模型。
图示口径：CW-019 已验收架构图；本页用大字号边界说明。

现场演示：Docker 只读合成链路

前提：Docker Desktop + Compose v2 + 已授权 bundle

```
docker compose -f compose.demo.yaml up --build -d
```

```
python scripts/verify_demo.py
```

```
docker compose -f compose.demo.yaml down --remove-orphans
```

历史预期：live / ready / model / policy / score 通过，错误输入返回 422。

CW-018 report.json：六项检查通过、合成常量特征、无持久化、未调用 LLM。
本包不新增容器实测。

两种失败都要可解释地关闭

输入边界

缺列、类型或批量不合法
→ 422

不执行部分评分

资产边界

bundle / policy 摘要不匹配
→ 服务不就绪或 preflight 失败

不静默替换模型

调查候选的校验失败 → rejected / insufficient_evidence

证据边界：哪些是事实，哪些是限制

已验收证据

CW-018：本机 Docker 合成演示
CW-019：架构、数据流、取舍和 PNG 图源
Actions：冻结门禁与安全报告

研究限制

输入是匿名/合成研究数据
模型分数未校准，不是欺诈概率
研究型等级不是生产处置
默认不调用 DeepSeek

演示材料保留限制，是为了让结果可审查。

复现入口

代码与文档

README.md
docs/docker_demo.md
docs/architecture.md

验收材料

CW-018 acceptance.md
CW-019 acceptance.md
本包脚本与 PPT/PDF

一句话收束：评分链路可复现，调查链路可审查，失败边界可解释。